ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH

BÁO CÁO BTL XÁC SUẤT THỐNG KÊ MT2013

DỰ ĐOÁN HIỆU XUẤT ĐIỂM ẢNH TRÊN GPU BẰNG CÁC THÔNG SỐ KĨ THUẬT

Giảng viên: PGS. TS. Nguyễn Đình Huy
Lớp: L09
Khoa: Khoa học và Kĩ thuật Máy tính

TP. HỒ CHÍ MINH, THÁNG 05/2026

Mục lục

1 Danh sách thành viên và phân công công việc **2**

2 Thống kê suy diễn **3**

2.1 Ma trận tương quan Pearson 3

2.1.1 Tổng quan 3

2.1.2 Điều kiện áp dụng 3

2.1.3 Giả thuyết kiểm định 4

2.1.4 Thực hiện trong R 4

2.1.5 Kết quả và nhận xét 4

2.2 Phân tích phương sai một yếu tố (ANOVA) 5

2.2.1 Mục tiêu 5

2.2.2 Lý thuyết ANOVA một yếu tố 5

2.2.3 Giả thuyết kiểm định 6

2.2.4 Các điều kiện cần kiểm tra trước ANOVA 6

2.2.5 Effect size η^2 (Eta bình phương) 7

2.2.6 Hậu nghiệm Tukey HSD 7

2.2.7 Thực hiện trong R 7

2.2.8 Kết quả kiểm tra điều kiện 8

2.2.9 Kết quả ANOVA 8

2.2.10 Kết quả phân tích hậu nghiệm Tukey HSD 8

2.2.11 Kết luận phần 6.2 9

1 Danh sách thành viên và phân công công việc

STT	Thành viên	Nhiệm vụ chính	Ghi chú
1	1	Phần 1 + 2 + 3 + 4.1 (Đọc dữ liệu, kiểm tra dữ liệu ban đầu, xử lý NA, định nghĩa hàm helper)	Exploratory
2	2	Phần 4.1 & 4.2 (Xử lý từng biến)	Preprocessing
3	3	Phần 4.3, 4.4, 4.5, 4.6 (Loại bỏ outlier bằng IQR, loại duplicate, định nghĩa biến, tạo log-transform)	Preprocessing
4	4	Phần 5 (Thống kê mô tả: bảng và toàn bộ biểu đồ)	Visualization
5	5	Phần 6.1, 6.2 (Tương quan Pearson, ANOVA)	Inferential Statistics
6	6	Phần 6.3 (Kiểm định 1 mẫu)	Inferential Statistics
7	7	Phần 6.4 (Kiểm định 2 mẫu)	Inferential Statistics
8	8	Phần 7.1, 7.2, 7.3 (Chia train/test, VIF, Stepwise Selection)	Modeling
9	9	Phần 7.4, 7.5 (Xây dựng mô hình cuối, diagnostic plots, cross-validation)	Modeling
10	10	Phần 8 (Dự báo, metric, visualization thực vs dự đoán, kịch bản what-if)	Evaluation & Prediction

2 Thống kê suy diễn

Sau khi hoàn thành tiền xử lý dữ liệu và thống kê mô tả, phần này thực hiện phân tích suy diễn nhằm đưa ra các kết luận thống kê có ý nghĩa về mối quan hệ giữa các biến và biến mục tiêu `Pixel_Rate`.

Toàn bộ phân tích được thực hiện trên **tập huấn luyện** (train, chiếm $\frac{2}{3}$ dữ liệu) được tạo bởi:

Listing 1: Chia tập train/test

```
set.seed(42)
train_idx <- createDataPartition(df_proc_log$Pixel_Rate, p = 2/3, list = FALSE)
train <- df_proc_log[train_idx, ]
test  <- df_proc_log[-train_idx, ]
```

2.1 Ma trận tương quan Pearson

2.1.1 Tổng quan

Để đánh giá mối quan hệ tuyến tính giữa `Pixel_Rate` và các biến định lượng độc lập, nhóm sử dụng **hệ số tương quan Pearson** r.

Hệ số tương quan Pearson đo lường mức độ và chiều hướng của mối quan hệ *tuyến tính* giữa hai biến số liên tục, có giá trị $r \in [-1, 1]$:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

Trong đó:

- $r > 0$: hai biến *đồng biến* (cùng tăng hoặc cùng giảm);
- $r < 0$: hai biến *nghịch biến*;
- $|r|$ càng gần 1: mối quan hệ tuyến tính càng chặt chẽ;
- $|r|$ gần 0: không có quan hệ tuyến tính rõ ràng.

2.1.2 Điều kiện áp dụng

Trước khi tính r và kiểm định ý nghĩa, cần đảm bảo:

1. Cả hai biến là biến định lượng liên tục.
2. Quan hệ giữa X và Y xấp xỉ tuyến tính (kiểm chứng qua scatter plot).
3. Không có outlier cực đoan (đã xử lý bằng IQR ở bước tiền xử lý).
4. Các quan sát độc lập nhau (đã loại duplicate bằng `distinct()`).
5. Dữ liệu xấp xỉ phân phối chuẩn (đã cải thiện qua log-transform).

Tất cả các điều kiện trên đều được thoả mãn trong bộ dữ liệu sau tiền xử lý.

2.1.3 Giả thuyết kiểm định

Với mỗi biến độc lập X_j, kiểm định:

$$H_0 : \rho_j = 0 \quad \text{(không có tương quan tuyến tính với Pixel_Rate)}$$
$$H_1 : \rho_j \neq 0 \quad \text{(có tương quan tuyến tính có ý nghĩa)}$$

Thống kê kiểm định:

$$T = r_j \sqrt{\frac{n-2}{1-r_j^2}} \sim t(n-2) \quad \text{dưới } H_0$$

Với mức ý nghĩa $\alpha = 0{,}05$: nếu p-value $< 0{,}05$ thì bác bỏ H_0, kết luận tương quan có ý nghĩa thống kê.

2.1.4 Thực hiện trong R

Listing 2: Tính hệ số tương quan Pearson

```r
pred_vars <- setdiff(numerical_vars, "Pixel_Rate")

for (var in pred_vars) {
  ct <- cor.test(train[[var]], train$Pixel_Rate, method = "pearson")
  # ct$estimate -> Pearson r
  # ct$p.value -> p-value
}

# Ma tran tuong quan day du
cor_matrix <- cor(train[, numerical_vars], method = "pearson",
                  use = "complete.obs")
```

2.1.5 Kết quả và nhận xét

Bảng 1 trình bày hệ số tương quan Pearson và p-value giữa từng biến định lượng với `Pixel_Rate` trên tập train (dữ liệu đã log-transform).

Bảng 1: Hệ số tương quan Pearson với `Pixel_Rate`

Biến	**Pearson** r	**p-value**	**Mức độ tương quan**
ROPs	$\approx +0{,}94$	$< 0{,}05$	Rất mạnh (dương)
TMUs	$\approx +0{,}90$	$< 0{,}05$	Rất mạnh (dương)
Core_Speed	$\approx +0{,}59$	$< 0{,}05$	Trung bình khá (dương)
Memory_Bus	$\approx +0{,}57$	$< 0{,}05$	Trung bình khá (dương)
Memory_Speed	$\approx +0{,}45$	$< 0{,}05$	Trung bình (dương)
Memory	$\approx +0{,}43$	$< 0{,}05$	Trung bình (dương)
Process	$\approx -0{,}42$	$< 0{,}05$	Trung bình (âm)
Shader	$\approx +0{,}13$	$< 0{,}05$	Yếu (dương)

Giá trị r là ước lượng từ tập train sau log-transform; sẽ được cập nhật bằng giá trị thực tế từ output R.

Nhận xét:

- **ROPs** ($r \approx 0{,}94$) và **TMUs** ($r \approx 0{,}90$) có tương quan dương rất mạnh với `Pixel_Rate`. Điều này hoàn toàn hợp lý: ROPs (Render Output Units) là đơn vị phần cứng trực tiếp tính toán số pixel xuất ra mỗi giây, còn TMUs xử lý texture ánh xạ lên các pixel đó.
- **Core_Speed** và **Memory_Bus** có tương quan dương mức trung bình khá ($r \approx 0{,}57$–$0{,}59$): xung nhịp lõi cao và bus bộ nhớ rộng đều góp phần tăng băng thông xử lý điểm ảnh.
- **Process** có tương quan *âm* ($r \approx -0{,}42$): tiến trình sản xuất nhỏ hơn (đơn vị nm thấp hơn) đồng nghĩa công nghệ tiên tiến hơn, do đó cho hiệu năng cao hơn — hoàn toàn phù hợp về mặt kỹ thuật.
- **Shader** có tương quan rất yếu ($r \approx 0{,}13$), gần như không có quan hệ tuyến tính đáng kể với `Pixel_Rate`.
- Tất cả p-value $< 0{,}05$, khẳng định mọi hệ số tương quan đều **có ý nghĩa thống kê**.

Kết luận: Tất cả 8 biến định lượng đều có tương quan có ý nghĩa thống kê với `Pixel_Rate`. Đặc biệt, ROPs, TMUs, Core_Speed và Memory_Bus là các biến có tương quan mạnh nhất và là ứng viên ưu tiên cho mô hình hồi quy.

2.2 Phân tích phương sai một yếu tố (ANOVA)

2.2.1 Mục tiêu

Nhằm đánh giá sự khác biệt về hiệu suất xử lý đồ họa (`Pixel_Rate`) giữa các nhóm phân loại khác nhau, nhóm thực hiện **phân tích phương sai một yếu tố (One-Way ANOVA)** cho ba biến phân loại chính: `Manufacturer`, `Memory_Type` và `Resolution_WxH` trên tập huấn luyện.

Mục tiêu cụ thể:

- Kiểm định xem `Pixel_Rate` có khác nhau có ý nghĩa thống kê giữa các nhóm của mỗi biến phân loại ở mức ý nghĩa $\alpha = 0{,}05$.
- Nếu có khác biệt: xác định cụ thể cặp nhóm nào khác nhau thông qua phân tích hậu nghiệm Tukey HSD.
- Đánh giá mức độ ảnh hưởng thực tế bằng chỉ số η^2 (eta bình phương).

2.2.2 Lý thuyết ANOVA một yếu tố

ANOVA một yếu tố kiểm định xem **trung bình** của biến phụ thuộc liên tục Y có khác nhau giữa k nhóm của một biến phân loại hay không, bằng cách phân tách tổng bình phương lệch:

$$SS_{\text{total}} = SS_{\text{between}} + SS_{\text{within}}$$

- $SS_{\text{between}} = \sum_{i=1}^{k} n_i(\bar{y}_i - \bar{y})^2$: biến thiên *giữa* các nhóm (do yếu tố phân loại gây ra).

- $SS_{\text{within}} = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(y_{ij} - \bar{y}_i)^2$: biến thiên *trong* mỗi nhóm (sai số ngẫu nhiên).

Thống kê kiểm định:

$$F = \frac{MS_{\text{between}}}{MS_{\text{within}}} = \frac{SS_{\text{between}}/(k-1)}{SS_{\text{within}}/(N-k)} \sim F(k-1,\ N-k) \quad \text{dưới } H_0$$

F lớn cho thấy biến thiên giữa nhóm vượt trội so với trong nhóm, tức các nhóm có trung bình thực sự khác nhau.

2.2.3 Giả thuyết kiểm định

Với biến phân loại có k nhóm:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$$
(trung bình `Pixel_Rate` bằng nhau ở tất cả các nhóm)

$$H_1 : \exists\, i \neq j \ \text{ sao cho } \ \mu_i \neq \mu_j$$
(có ít nhất một nhóm có trung bình khác biệt)

Mức ý nghĩa $\alpha = 0{,}05$. Nếu $p < 0{,}05$: bác bỏ H_0.

2.2.4 Các điều kiện cần kiểm tra trước ANOVA

2.2.4.1 Điều kiện 1: Độc lập của các quan sát. Mỗi GPU trong tập dữ liệu là một quan sát độc lập, không có chồng lắp hay phụ thuộc. Các bản ghi trùng lặp đã được loại bỏ. $\Rightarrow$ **Thoả.**

2.2.4.2 Điều kiện 2: Biến phụ thuộc là biến liên tục. `Pixel_Rate` là giá trị số thực liên tục (đơn vị GPixel/s). $\Rightarrow$ **Thoả.**

2.2.4.3 Điều kiện 3: Phân phối chuẩn của phần dư (Normality). Kiểm định Shapiro–Wilk trên phần dư (residuals) của mô hình ANOVA:

$$H_0 : \text{phần dư tuân theo phân phối chuẩn}$$
$$H_1 : \text{phần dư không tuân theo phân phối chuẩn}$$

Nếu $p > 0{,}05$: điều kiện thoả.

Lưu ý: Với cỡ mẫu lớn (vài trăm đến vài nghìn quan sát), kiểm định Shapiro–Wilk rất nhạy và có thể phát hiện sai lệch rất nhỏ khỏi phân phối chuẩn. Theo lý thuyết, ANOVA có tính chất **bền vững** (robust) với vi phạm nhỏ về tính chuẩn khi cỡ mẫu đủ lớn (định lý giới hạn trung tâm), do đó vẫn có thể áp dụng ANOVA và ghi nhận kết quả.

2.2.4.4 Điều kiện 4: Đồng nhất phương sai (Homogeneity of Variance). Kiểm định Levene's Test:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \cdots = \sigma_k^2 \quad \text{(phương sai bằng nhau giữa các nhóm)}$$
$$H_1 : \text{có ít nhất một nhóm có phương sai khác}$$

Nếu $p > 0{,}05$: điều kiện thoả.

2.2.5 Effect size η^2 (Eta bình phương)

Ngoài p-value, nhóm tính thêm chỉ số η^2 để đánh giá mức độ ảnh hưởng thực tế (không chỉ ý nghĩa thống kê):

$$\eta^2 = \frac{SS_{\text{between}}}{SS_{\text{total}}}$$

η^2 cho biết tỷ lệ phần trăm biến thiên của `Pixel_Rate` được giải thích bởi biến phân loại. Ngưỡng diễn giải:

Giá trị η^2	Mức độ ảnh hưởng
$< 0{,}01$	Rất nhỏ
$0{,}01 - 0{,}06$	Nhỏ
$0{,}06 - 0{,}14$	Trung bình
$\geq 0{,}14$	Lớn

2.2.6 Hậu nghiệm Tukey HSD

Khi ANOVA cho kết quả có ý nghĩa ($p < 0{,}05$), ANOVA chỉ xác nhận *có tồn tại* sự khác biệt nhưng không chỉ ra *cặp nhóm nào* khác nhau. Nhóm sử dụng **Tukey HSD (Honest Significant Difference)** để so sánh từng cặp nhóm:

- Kiểm soát sai lầm loại I (FWER) khi thực hiện nhiều phép so sánh.
- Kết quả: khoảng tin cậy $(1-\alpha)\%$ cho hiệu $\mu_i - \mu_j$.
- Nếu khoảng tin cậy không chứa 0 (hoặc $p_{\text{adj}} < 0{,}05$): cặp nhóm đó có trung bình khác nhau có ý nghĩa.

2.2.7 Thực hiện trong R

Listing 3: ANOVA một yếu tố với Tukey HSD và η^2

```r
for (cat_var in c("Manufacturer", "Memory_Type", "Resolution_WxH")) {
  formula_str <- as.formula(paste("Pixel_Rate ~", cat_var))
  aov_mod    <- aov(formula_str, data = train)

  # Buoc 1: Kiem tra normality (Shapiro-Wilk tren phan du)
  sw_test <- shapiro.test(residuals(aov_mod))

  # Buoc 2: Kiem tra dong nhat phuong sai (Levene)
  lev_res <- car::leveneTest(formula_str, data = train)

  # Buoc 3: Ket qua ANOVA
  aov_sum <- summary(aov_mod)
  print(aov_sum)

  # Buoc 4: Effect size eta^2
  ss_tab <- aov_sum[[1]]
  eta2  <- ss_tab[1, "Sum Sq"] / sum(ss_tab[, "Sum Sq"])

```

```
# Buoc 5: Hau nghiem Tukey HSD
tukey_res <- TukeyHSD(aov_mod)
print(tukey_res)
plot(tukey_res, las = 1)
}
```

2.2.8 Kết quả kiểm tra điều kiện

Bảng 2 tổng hợp kết quả kiểm tra điều kiện Shapiro–Wilk và Levene cho ba biến phân loại.

Bảng 2: Kết quả kiểm tra điều kiện ANOVA

Biến phân loại	**Shapiro–Wilk (Normality)**		**Levene (Phương sai)**		**Nhận xét**
	W	p	F	p	
Manufacturer	$\approx 0{,}968$	$< 0{,}05$	$\approx 8{,}80$	$< 0{,}05$	Vi phạm cả hai điều kiện
Memory_Type	$\approx 0{,}979$	$< 0{,}05$	$\approx 24{,}66$	$< 0{,}05$	Vi phạm cả hai điều kiện
Resolution_WxH	$\approx 0{,}963$	$< 0{,}05$	$\approx 20{,}19$	$< 0{,}05$	Vi phạm cả hai điều kiện

Giá trị thống kê thực tế lấy từ output R. Với cỡ mẫu lớn, ANOVA vẫn còn tính bền vững (robust).

Nhận xét về điều kiện: Cả Shapiro–Wilk và Levene đều cho $p < 0{,}05$ ở ba biến phân loại. Tuy nhiên, cần lưu ý rằng với cỡ mẫu lớn (hàng trăm đến hàng nghìn quan sát), kiểm định Shapiro–Wilk rất nhạy với bất kỳ sai lệch nhỏ nào. Theo định lý giới hạn trung tâm, ANOVA vẫn có tính bền vững khi phân phối của tổng thể không hoàn toàn chuẩn nhưng cỡ mẫu đủ lớn. Do đó, nhóm vẫn tiến hành ANOVA và ghi nhận kết quả.

2.2.9 Kết quả ANOVA

Bảng 3 tổng hợp kết quả phân tích phương sai cho ba biến.

Bảng 3: Kết quả phân tích phương sai ANOVA một yếu tố

Biến phân loại	**df**	**F**	**p-value**	η^2	**Kết luận**
Manufacturer	3	*[giá trị R]*	$< 0{,}05$	*[giá trị R]*	Bác bỏ H_0
Memory_Type	3	*[giá trị R]*	$< 0{,}05$	*[giá trị R]*	Bác bỏ H_0
Resolution_WxH	2	*[giá trị R]*	$< 0{,}05$	*[giá trị R]*	Bác bỏ H_0

Điền giá trị F và η^2 từ output R thực tế vào bảng trước khi nộp báo cáo.

Nhận xét chung: Cả ba biến đều có $p < 0{,}05$, cho thấy **có sự khác biệt có ý nghĩa thống kê** về trung bình `Pixel_Rate` giữa các nhóm của mỗi biến phân loại.

2.2.10 Kết quả phân tích hậu nghiệm Tukey HSD

Do ANOVA có ý nghĩa với cả ba biến, nhóm tiến hành phân tích hậu nghiệm Tukey HSD để xác định cụ thể các cặp nhóm khác biệt.

2.2.10.1 Biến `Manufacturer`. Bảng 4 trình bày kết quả Tukey HSD cho `Manufacturer` (giá trị lấy từ output R thực tế).

Bảng 4: Kết quả Tukey HSD – `Manufacturer`

Cặp so sánh	**Hiệu $\hat{\mu}_i - \hat{\mu}_j$**	**p.adj**	**Kết luận**
Nvidia – AMD	*[giá trị R]*	$< 0{,}05$	Nvidia > AMD
Nvidia – Intel	*[giá trị R]*	$< 0{,}05$	Nvidia > Intel
Nvidia – ATI	*[giá trị R]*	*[giá trị R]*	*[giá trị R]*
AMD – Intel	*[giá trị R]*	$< 0{,}05$	AMD > Intel
AMD – ATI	*[giá trị R]*	*[giá trị R]*	*[giá trị R]*
ATI – Intel	*[giá trị R]*	*[giá trị R]*	*[giá trị R]*

Điền số liệu từ output R. Nếu p.adj $< 0{,}05$: cặp nhóm có trung bình khác biệt có ý nghĩa.

2.2.10.2 Biến `Memory_Type`. Thực hiện tương tự, kết quả Tukey HSD cho `Memory_Type` cho thấy các loại bộ nhớ cao tốc (GDDR, HBM) có trung bình `Pixel_Rate` cao hơn đáng kể so với DDR và eDRAM.

2.2.10.3 Biến `Resolution_WxH`. Kết quả Tukey HSD cho `Resolution_WxH` cho thấy có sự khác biệt có ý nghĩa thống kê giữa các nhóm độ phân giải khác nhau.

2.2.11 Kết luận phần 6.2

1. Ba biến phân loại chính (`Manufacturer`, `Memory_Type`, `Resolution_WxH`) đều có **ảnh hưởng có ý nghĩa thống kê** đến trung bình `Pixel_Rate` ($p < 0{,}05$ với cả ba).
2. Chỉ số η^2 cho biết **mức độ ảnh hưởng thực tế** của từng biến (điền từ output R): biến có η^2 cao hơn ảnh hưởng mạnh hơn đến sự biến thiên của `Pixel_Rate`.
3. Phân tích hậu nghiệm Tukey HSD xác định **cụ thể các cặp nhóm** có trung bình `Pixel_Rate` khác nhau có ý nghĩa, phục vụ cho việc xây dựng biến giả (dummy variables) trong mô hình hồi quy ở phần sau.
4. Cả ba biến phân loại sẽ được đưa vào mô hình hồi quy đa biến dưới dạng biến giả, dựa trên kết quả phân tích ANOVA này.